Hoja de ejercicios. Tema 1

1.- [Avanzado][Distribuciones en el muestreo] Consideramos los siguientes estadísticos:

(a) $\frac{\bar{X}_n-\mu}{\sigma/\sqrt{n}}$ (b) $\frac{\bar{X}_n-\mu}{S/\sqrt{n}}$ (c) $\frac{(n-1)S^2}{\sigma^2}$ (d) $\frac{X_1+X_n}{2}$ e) $n\,\bar{X}_n$

Considera las siguientes situaciones e indica si tienes un soporte teórico para determinar la distribución de los 5 estadísticos:

A) Se toman 1000 muestras de tamaño 10 de una distribución normal de media 50 y desviación estándar 12.
B) Se toman 1000 muestras de tamaño 10 de una distribución de media 50 y desviación estándar desconocida.
C) Se toman 1000 muestras de tamaño 40 de una Poisson de parámetro 5
D) Se toman 1000 muestras de tamaño 1000 de una binaria de parámetro 0.6.
E) Se toman 1000 muestras de tamaño 100 de una distribución exponencial de media 2.

2.- [Potencia] Los siguientes ejercicios profundizan en el concepto de potencia

2.1 Supongamos que tenemos una bolsa con 100 bolas, que son negras y blancas. Planteamos un contraste con hipótesis nula: "la mitad o menos de las bolas son blancas". Extraemos una bola, si sale blanca, rechazamos la hipótesis nula.
   a. Calcula el nivel de significación de este contraste
   b. Si la realidad es que hay 60 bolas blancas en la urna, ¿qué potencia tiene este contraste?

2.2 Una variable aleatoria X es normal con desviación típica 2 y media desconocida μ . Si para resolver el contraste H1:μ>2 rechazamos la nula cuando la media de una muestra de tamaño 9 es mayor que 2.4, ¿cuál es el nivel de significación?¿ cuál es la potencia de este contraste si la media poblacional de la variable realmente es 2.5?

2.3 **[Avanzado]** [T1_II_3] Los datos adjuntos proceden de un estudio sobre el consumo y contaminación de CO2 de varios coches que se venden actualmente en el mercado. Del catálogo total de coches, se hace una selección de 100 coches. Se plantea si el consumo en autopista (**cons-auto**) es significativamente menor que el consumo en ciudad (**cons-ciu**). Resuélvelo por el método adecuado y obtén la potencia del este contraste si en la realidad en ciudad se consume una media de 0.5 l más que en autopista por cada 100km.

2.4 [Avanzado] [T1_II_3] Con los mismo datos del ejercicio anterior nos planteamos si las emisiones de CO2 medidas en gramos por kilómetro recorrido (**co2**) son significativamente mayores en los vehículos de grado de contaminación (**contaminante**) **alto** frente a los de grado **medio.** Resuélvelo por el método adecuado y obtén la potencia del este contraste si en la realidad el consumo de los de grado alto su emisión de co2 supera los de grado medio en 10 gramos por kilómetro recorrido

3.- [Potencia: Curva ROC]

Este ejercicio se puede hacer con el código de los apuntes para evitar tiempo de cálculo, pero está pensado para hacerlo a mano.

En el diagnóstico de anemia ferropénica (Fe) se mide el volúmen corpuscular medio (VCM) como "patrón de oro" para diagnosticar la existencia de depósitos de hierro en la médula ósea

Tabla de datos

VCM

Sin Fe (n=34): 52, 58, 62, 65, 67, 68, 69, 71, 72, 72, 73, 73, 74, 75, 76, 77, 77, 78, 79, 80, 80, 81, 81, 81, 82, 83, 84, 85, 85, 86, 88, 88, 90, 92

Con Fe (n=66): 60, 66, 68, 69, 71, 71, 73, 74, 74, 74, 76, 77, 77, 77, 77, 78, 78, 79, 79, 80, 80, 81, 81, 81, 82, 82, 83, 83, 83, 83, 83, 83, 83, 84, 84, 84, 84, 85, 85, 86, 86, 86, 87, 88, 88, 88, 89, 89, 89, 90, 90, 91, 91, 92, 93, 93, 93, 94, 94, 94, 94, 96, 97, 98, 100, 103

En los datos anteriores se observa solapamiento en los valores de VCM entre los individuos con anemia y sin anemia. Por esa razón se estudian distintos punto de corte para el diagnóstico.

a) Considera los puntos de corte: 65, 70, 75, 80, 85, 90, 92 y completa la tabla con cabecera:

Punto Corte	Sensibilidad	1-Especificidad

b) Dibuja la curva ROC, calcula la AUC e indica cuál sería el punto de corte óptimo para hacer el diagnóstico de anemia con el índice de Youden.
c) Introduce los datos en R para resolver el apartado b) con el paquete pROC.

4.- [Exactitud y precisión] Cuatro laboratorios farmacéuticos, que llamaremos A, B, C y D, realizan 5 determinaciones, cada uno de ellos, de una muestra de sangre cuya lectura real suponemos conocida e igual a 10.00 ml. Las determinaciones obtenidas por los cuatro laboratorios (en ml.) son las siguientes

Laboratorio A	Laboratorio B	Laboratorio C	Laboratorio D
10.09	9.88	9.79	10.04
10.10	10.02	10.19	10.02
10.08	10.14	9.78	9.98
10.11	10.21	10.05	9.97
10.12	9.80	9.69	10.04

a) Calcula el error absoluto medio y el coeficiente de variación (RSD) para los datos de cada laboratorio
b) Efectúa el gráfico de puntos (dot plot) para observar el comportamiento de los datos de cada laboratorio.
c) Establece para cada laboratorio si la exactitud y la precisión son altas o bajas.

5.- [Error cuadrático medio] De una población de la que observamos una variable aleatoria X con media μ y desviación σ desconocidas, extraemos una muestra.

En los apartados a)-d) se proporcionan parejas de estimadores de μ y debes escoger uno de los dos siguiendo el criterio del mínimo ECM (error cuadrático medio).

a) $\hat{\theta}_1$ y $\hat{\theta}_2$ son insesgados con varianza 10 y 4 respectivamente
b) $\mathrm{E}[\hat{\theta}_1] = \theta$; $\mathrm{E}[\hat{\theta}_2] = \theta/2$; y varianzas 10 y 4 respectivamente
c) $\mathrm{E}[\hat{\theta}_1] = \mathrm{E}[\hat{\theta}_2] = \theta$ y $\mathrm{E}[\hat{\theta}_3] \neq \theta$; $\mathrm{Var}[\hat{\theta}_1] = 12$; $\mathrm{Var}[\hat{\theta}_2] = 10$; $\mathrm{E}[(\hat{\theta}_3 - \theta)^2] = 6$
d) **[avanzado]**Dada una muestra aleatoria simple de tamaño 2n, $\hat{\theta}_1 = \frac{1}{2n}\sum_{i=1}^{2n} X_i$, $\hat{\theta}_2 = \frac{1}{n}\sum_{i=1}^{n} X_i$
e) **[avanzado]**Tres muestras aleatorias simples de tamaño 20, 10, 8 y varianzas muestrales S_1^2, S_2^2, S_3^2, calcula la esperanza de $S^2 = \frac{20S_1^2 + 10S_2^2 + 8S_3^2}{38}$.
f) **[avanzado]**Sea X una variable aleatoria con media μ y desviación σ. Dadas dos muestras aleatorias independientes de tamaños n_1 y n_2 con medias muestrales $\bar{X}_1$ y $\bar{X}_2$, comprueba que el estimador de la media de X:

$$\hat{\theta} = a\bar{X}_1 + (1-a)\bar{X}_2 \quad 0<a<1$$

es centrado. Calcula el valor de *a* que minimice el error estándar de $\hat{\theta}$.

6.-**[Estimación máximo verosímil] O**btén el MLE de los parámetros a partir de una m.a.s de tamaño n.

a) Consideramos la variable aleatoria X con función de densidad

$$f(x) = \begin{cases} (\alpha+1)x^{\alpha} & 0 < x < 1 \\ 0 & resto \end{cases}$$

Dada una m.a.s. de tamaño n, obtén el MLE de α.

b) En una urna hay bolas blancas, rojas y azules en una proporción que desconocemos. Extraemos n bolas y a son blancas, b son rojas y n-a-b son azules. Si nos dicen que la proporción de rojas es el doble que la de blancas, obtén el estimador máximo verosímil de la proporción de bolas blancas.

c)[avanzado] **c.1** La distribución exponencial modificada tiene función de densidad

$$f(x) = \begin{cases} \lambda e^{-\lambda(x-\theta)} & \theta < x \\ 0 & resto \end{cases}$$

Cuando $\theta = 0$ es la distribución exponencial común. Solo cuando $\theta > 0$ tiene sentido

c.2 Obtén los estimadores ML de la media μ y desviación σ de una normal.

7.- **[Ajuste de distribuciones]**

a) El sorgo es un cereal importante cuya calidad y apariencia podría verse afectada por la presencia de pigmentos en el pericarpio (las paredes del ovario de la planta). Se efectúa un experimento genético que consiste en cruzar sorgo CK60 (semilla blanca) con sorgo Abu Taima (semilla amarilla) para producir semillas rojas que vuelven a cruzarse entre sí. La teoría genética debe producir plantas con semillas rojas, amarillas o blancas en proporción 9:3:4. Los resultados del experimento, ¿contradicen o confirman la teoría genética?

Color semilla	Rojo	Amarilla	Blanca
Frecuencia	195	73	100

b) [T1_IV_3b] Los datos que se adjuntan son los diámetros de 45 tornillos. El proceso industrial asociado determina como estándar de calidad que los diámetros siguen una normal de media 0.5 y desviación 0.002. Efectúa la prueba adecuada para contrastar la normalidad. En caso de rechazo de la normalidad, efectúa la transformación Box-Cox adecuada para aproximar los datos a la normalidad. Comprueba con el contraste adecuado la normalidad de la variable transformada.

c) En un estudio de ecología se analiza población de pájaros la variable X=número de saltos que preceden al primer vuelo". El autor del estudio propone una distribución geométrica de parámetro "p". Para una muestra de tamaño 130 se obtuvieron los resultados:

saltos	0	1	2	3	4	5	6	7	8	9	10	11
frec	48	31	20	9	6	5	4	2	1	1	2	1

a) Obtén el estimador máximo verosímil de p
b) Efectúa el contrate chi-cuadrado con 7 celdas, siendo la última celda la que combina los valores mayores o iguales a 6.

8.- **[Asociación de variables]**

a) Se toman los datos de matriculación de la Universidad Pública de Navarra y se obtienen los siguientes resultados por facultades

	Hombres	Mujeres
CCSS	205	707
CCHHSS	518	1408
CCEE	611	546
ETSIAB	311	326
ETSIIT	1620	430
FCJ	247	391
Total	3586	3981

a.1 ¿Podemos decir que la proporción de hombres y mujeres matriculadas en la universidad es la misma? ¿Y en la ETSIAB?

a.2 Contrasta la asociación entre las variables sexo y facultad de pertenencia. [valor observado del estadístico y p-valor]

b) [avanzado] En la tabla adjunta se indican las proporciones muestrales totales que caen en cada categoría. Obtén el mínimo tamaño muestral n para el cual las proporciones observadas llevarían a rechazar la hipótesis de independencia. Ayuda: observa que en este ejercicio la información en cada casilla es $p_{ij}=n_{ij}/n$

	1	2	3
1	0.13	0.19	0.28
2	0.07	0.11	0.22

9.- [**Tablas de contingencia y su relación con otros contrastes**]

En la Encuesta Social y de condiciones de vida 2018 elaborada por el NASTAT (Instituto de Estadística de Navarra) se analizó el medio de transporte utilizado en la población navarra según diversas variables sociodemográficas. A partir de una muestra de 3716 individuos trabajadores o estudiantes se obtiene la tabla adjunta que incluye las variables X: edad e Y: medio de transporte utilizado principalmente para ir al trabajo o al centro de estudios

	Medio de transporte para ir a trabajar o a estudiar					
		A pie	En bici	Autobús	coche	otros
Grupos de edad	De 15 a 29 años	160	30	185	442	22
	De 30 a 44 años	162	41	57	984	18
	De 45 a 59 años	271	37	78	983	26
	De 60 y más años	45	**2**	**5**	89	3

Obtén las tablas de porcentajes y resuelve las cuestiones siguientes indicando con claridad los valores extraídos de estas tablas o la información utilizada de las salidas de R. Comprueba que has introducido bien la tabla, coteja tu tabla de porcentajes totales con la correcta, que es la siguiente:

a) Un grupo se considera sobrerrepresentado si hay una proporción de individuos en la muestra de ese grupo significativamente mayor que en la población. En este caso se sabe que el 55% de la población de estudio se encuentra en el grupo de 15 a 44 años, estudia si es significativa la sospecha de que este grupo de edad está sobrerrepresentado en el estudio. [Plantea el contraste y escribe la decisión a partir del p-valor]
b) Analiza el grado de asociación entre ambas variables. Escribe claramente el contraste y la decisión.
c) Si hay asociación, efectúa un breve informe en el que se utilice el análisis por perfiles fila y por perfiles columna para clarificar las siguientes cuestiones [recuerda que consideramos

asociación relevante a una diferencia de 10 o más puntos porcentuales respecto a lo esperado]:

i. En el grupo más joven hay comportamientos distintos al total, ¿en qué sentido?¿Aventurarías alguna razón?
ii. La bici no es un medio de transporte que se asocie en ningún sentido de manera relevante a un grupo de edad.

d) Volvemos a la cuestión a). Se sospecha que la muestra puede representar mal a los distintos grupos de edad. En la población en estudio (los que se desplazan de su casa para trabajar o estudiar) el porcentaje de 15 a 29 años es del 24%, de 30 a 44 es del 31%, de 45 a 59 es de 35% y el resto de más de 60 años. Resuelve con un único contraste la sospecha, plantea el contraste y resuélvelo. La fórmula del estadístico de contraste se relaciona con el utilizado en el apartado a) ¿cómo?

10.- **[Comportamiento teórico del test de Wilcoxon]**

a) En un test de Wilcoxon para una muestra de tamaño 4 obtenemos como valor observado del estadístico 2 y la hipótesis alternativa es H1: $\mu<3$. ¿Cuál es el p-valor?

b) [avanzado] Para entender el funcionamiento teórico de los estadísticos de los contrastes no paramétricos suponemos que tomamos una muestra de tamaño 4. Bajo la hipótesis nula del test Wilcoxon para una muestra tan probable es que un dato se quede por encima de la mediana como por debajo. Escribe todas las cadenas posibles de signos positivos-negativos de tamaño 4y obtén todos los posibles valores del estadístico W. Establece para qué valores es significativo un contraste unilateral y un contraste bilateral con nivel de significación del 0.05.

*11.-**[Elección del contraste adecuado]***

11.1) [T1_V_14bis] La resistencia del papel es proporcional al grado de polimerización de la celulosa. La polimerización es un proceso que lleva un tiempo que le empresa quiere reducir. La pasta de papel se prepara en un tanque y se remueve mecánicamente durante todo el proceso (agitación de la pasta) lo que hace ir aumentando el grado con el tiempo. Se mide, en cada tanque, la polimerización al comienzo del proceso y transcurrida una hora del proceso. La hipótesis de trabajo es que el grado de polimerización aumenta al cabo de una hora.

a) Plantea el contraste que debes resolver para confirmar la hipótesis de trabajo. Indica **razonadamente** el estadístico del contraste paramétrico más potente que utilizarías para resolverlo. Comprueba sus hipótesis (escribe H1 del contraste utilizado y la decisión) y resuélvelo si es posible.

b) Resuelve el correspondiente contraste no paramétrico. Indica el valor observado del estadístico de contraste y la decisión. Indica qué probabilidad representa el p-valor respecto al valor observado del estadístico de contraste.

c) Indica con respecto a la potencia del contraste qué ventaja tiene hacer el diseño propuesto frente a otro que considerara 34 tanques distintos, de manera que 17 se utilizaran para medir el grado de polimerización al inicio y otros 17 distintos para hacer la medición a la hora.

11.2) [T1_V_14] Se mide la resistencia del papel producido y se distingue según se haya hecho con una pasta de baja o de alta viscosidad. Se considera la resistencia del papel Kraft para un nivel BAJO de viscosidad de la pasta de papel y la resistencia para un nivel ALTO de viscosidad de la pasta de papel. La hipótesis de trabajo es que la resistencia es mayor con niveles altos que con niveles bajos de viscosidad de la pasta de papel.

a) Efectúa el diagrama de cajas apropiado, dibújalo e interprétalo razonadamente justificando si apoya o no la hipótesis de trabajo (un buen razonamiento suele relacionar los cuartiles de ambas cajas).

b) Plantea el contraste que debes resolver para confirmar la hipótesis de trabajo. Indica razonadamente el estadístico del contraste paramétrico más potente que utilizarías para resolverlo.

c) Comprueba si se cumplen las hipótesis para aplicar el contraste indicado en el apartado b. Plantea claramente los contrastes que has resuelto, el valor observado del estadístico de contraste y la decisión.

d) Resuelve el correspondiente contraste no paramétrico. Indica el valor observado del estadístico de contraste y la decisión.

e) ¿Qué conclusión obtienes finalmente? ¿Harías alguna sugerencia de mejora en el procedimiento estadístico a la vista del p-valor?

11.3) [T1_VII_5] El elevado consumo de energía durante el ejercicio continúa después de que termina el trabajo físico. Los datos adjuntos miden el consumo de oxígeno en los treinta minutos después del entrenamiento de una muestra de 15 individuos, esta medición se hace a cada uno de los 15 individuos después de un entrenamiento de PESAS y después de un entrenamiento de CINTA de correr. Un mayor consumo refleja un mayor gasto calórico. [2.5]

a) Plantea un contraste para confirmar la hipótesis de trabajo de que una vez acabados los ejercicios de pesas estos generan un mayor gasto calórico que los de cinta. Resuelve el contraste con el método adecuado.

b) Se quiere saber si ambos ejercicios generan en los individuos consumos de oxígeno relacionados. Para ello
   i. Realiza un estudio no paramétrico de la relación (correlación por rangos) e interpreta el resultado.
   ii. Escribe e interpreta el significado de la pendiente en los siguientes ajustes (suponemos que estos ajustes tienen sentido) y valora la calidad del ajuste propuesto.

   $ii.1$ $\widehat{Cinta}$=a+b*Pesas

   ii.2 $\log\widehat{(Cinta)}$=a+b*log(Pesas)

c) Si añadimos un individuo con valores PESAS=35 y CINTA=60 se produce una variación del coeficiente de Pearson y del coeficiente de Spearman, pero de distinta magnitud. Explica brevemente cuál es la razón.

12.-[Elección del contraste adecuado] *Comparación de más de tres variables En los siguientes ejercicios debes realizar los siguientes pasos:*

a) Comparar mediante el correspondiente gráfico de cajas el comportamiento de las variables. Acompaña el análisis con algún estudio descriptivo breve.

b) Aplicar Kruskal-Wallis/ANOVA o Friedman/ANOVA MR según corresponda, para resolver los contrastes. Comparar con los resultados en a).

12.1 [T1_V_8] El cortisol es una hormona de gran importancia para el metabolismo y el sistema inmune. Los datos muestran el nivel de cortisol en mujeres que dieron a luz en el intervalo de 38 a 42 semanas de embarazo. El grupo 1 eligió el parto por cesárea, el grupo 2 fue sometido a cesárea por urgencia y el grupo 3 tuvo un parto espontáneo. ¿Hay igualdad en la cantidad de cortisol independientemente del tipo de parto?

12.2 [T1_V_9] Se trata el suelo con 4 tratamientos (A, B, C, D) que mezclan en distintas proporciones agua y Basic-H. Asimismo, se consideraron 10 parcelas de suelo y a cada parcela se le aplicaron los cuatro tratamientos. A un nivel 0.01 ¿hay efecto debido al tratamiento?

12.3 [T1_V_10] Se analiza el nivel de colesterol en 8 individuos. Cada individuo fue sometido a una dieta de arroz durante un tiempo y a una dieta de patatas en otro periodo distinto y bien separado del anterior para evitar efectos cruzados. ¿Difiere el colesterol según la dieta recibida?

12.4 [T1_V_11] Se quiere estudiar si el nivel de concentración de fósforo en la superficie del suelo según el tipo de tratamiento cambia. Efectúa el análisis estadístico apropiado con los datos que se acompañan.